

Analisis Prediksi Diabetes Menggunakan Random Forest dengan Preprocessing Missing Value dan Visualisasi Data

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi dan internet menyebabkan jumlah data yang dihasilkan setiap hari meningkat sangat pesat. Fenomena ini dikenal dengan istilah big data. Big data merupakan kumpulan data dalam jumlah besar yang memiliki karakteristik volume, velocity, dan variety sehingga memerlukan teknik khusus dalam pengolahan dan analisisnya. Dalam berbagai bidang, termasuk kesehatan, analisis big data menjadi sangat penting untuk membantu proses pengambilan keputusan secara cepat dan akurat.

Salah satu penerapan analisis data pada bidang kesehatan adalah prediksi penyakit diabetes. Diabetes merupakan penyakit kronis yang terjadi akibat tingginya kadar gula dalam darah karena tubuh tidak mampu memproduksi insulin secara optimal atau tidak dapat menggunakan insulin dengan baik. Penyakit ini menjadi salah satu masalah kesehatan terbesar di dunia karena dapat menyebabkan berbagai komplikasi serius seperti gangguan ginjal, penyakit jantung, hingga kerusakan saraf.

Menurut data dari International Diabetes Federation (IDF), jumlah penderita diabetes terus mengalami peningkatan setiap tahunnya. Oleh karena itu, diperlukan metode analisis yang mampu membantu tenaga medis dalam melakukan prediksi dini terhadap kemungkinan seseorang mengalami diabetes. Dengan adanya prediksi dini, penanganan dapat dilakukan lebih cepat sehingga risiko komplikasi dapat dikurangi.

Dalam dunia data science, machine learning menjadi salah satu pendekatan yang sering digunakan untuk melakukan prediksi berdasarkan pola data historis. Machine learning memungkinkan komputer untuk mempelajari pola dari data

tanpa harus diprogram secara eksplisit. Salah satu algoritma machine learning yang banyak digunakan untuk klasifikasi adalah Random Forest.

Random Forest merupakan algoritma berbasis ensemble learning yang bekerja dengan menggabungkan banyak decision tree untuk meningkatkan akurasi prediksi dan mengurangi overfitting. Algoritma ini dipilih karena memiliki performa yang baik dalam menangani data numerik, mampu bekerja pada dataset dengan jumlah variabel yang cukup banyak, serta menghasilkan akurasi yang tinggi pada kasus klasifikasi.

Sebelum proses pembangunan model dilakukan, data perlu melalui tahap preprocessing terlebih dahulu. Tahapan preprocessing sangat penting karena kualitas data akan mempengaruhi performa model machine learning. Salah satu permasalahan umum dalam dataset adalah adanya missing value atau data yang hilang. Missing value dapat menyebabkan hasil analisis menjadi tidak akurat apabila tidak ditangani dengan baik.

Pada penelitian ini, apabila dataset tidak memiliki missing value, maka akan dilakukan simulasi missing value sebesar $\pm 5\%$ untuk menyesuaikan kondisi data nyata. Selanjutnya missing value tersebut akan ditangani menggunakan metode imputasi seperti mean dan median. Selain itu, dilakukan pula transformasi data berupa standardisasi agar skala antar variabel menjadi seragam.

Dataset yang digunakan dalam penelitian ini berasal dari platform Kaggle dengan topik diabetes prediction. Dataset tersebut memiliki beberapa variabel seperti glucose, blood pressure, insulin, BMI, usia, dan variabel target outcome yang menunjukkan apakah seseorang menderita diabetes atau tidak.

Berdasarkan latar belakang tersebut, penelitian ini dilakukan untuk menganalisis performa algoritma Random Forest dalam memprediksi penyakit diabetes dengan menerapkan preprocessing data, penanganan missing value, transformasi data, dan visualisasi data sebagai bagian dari proses analisis big data.

1.2 Identifikasi Masalah

Berdasarkan latar belakang yang telah dijelaskan, maka dapat diidentifikasi beberapa masalah sebagai berikut:

1. Dataset kesehatan sering memiliki permasalahan missing value yang dapat mempengaruhi kualitas analisis data.
2. Data numerik yang memiliki skala berbeda dapat menyebabkan performa model machine learning menjadi kurang optimal.
3. Diperlukan metode klasifikasi yang mampu memberikan hasil prediksi diabetes dengan tingkat akurasi yang baik.
4. Visualisasi data diperlukan untuk membantu memahami pola dan hubungan antar variabel dalam dataset.

1.3 Rumusan Masalah

Berdasarkan identifikasi masalah tersebut, maka rumusan masalah dalam penelitian ini adalah:

1. Bagaimana melakukan preprocessing data pada dataset diabetes?
2. Bagaimana cara menangani missing value menggunakan metode imputasi?
3. Bagaimana proses transformasi data dilakukan sebelum pembangunan model?
4. Bagaimana performa algoritma Random Forest dalam melakukan prediksi diabetes?
5. Bagaimana visualisasi data dapat membantu proses analisis dataset diabetes?

1.4 Tujuan Penelitian

Tujuan dari penelitian ini adalah:

1. Melakukan preprocessing data pada dataset diabetes.
2. Menangani missing value menggunakan metode imputasi mean dan median.
3. Melakukan transformasi data menggunakan standardisasi.
4. Membangun model klasifikasi menggunakan algoritma Random Forest.
5. Mengevaluasi performa model menggunakan metrik evaluasi klasifikasi.
6. Menampilkan visualisasi data untuk mendukung hasil analisis.

1.5 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat sebagai berikut:

1. Manfaat Teoritis

Penelitian ini diharapkan dapat menambah wawasan dan referensi mengenai penerapan machine learning, khususnya algoritma Random Forest dalam bidang kesehatan.

2. Manfaat Praktis

Penelitian ini diharapkan dapat membantu dalam memahami proses analisis data mulai dari preprocessing hingga evaluasi model machine learning.

3. Manfaat Akademis

Penelitian ini dapat dijadikan referensi bagi mahasiswa dalam mempelajari penerapan big data dan visualisasi data menggunakan Python.

1.6 Batasan Masalah

Agar penelitian lebih terarah, maka batasan masalah dalam penelitian ini adalah:

1. Dataset yang digunakan merupakan dataset diabetes dari Kaggle.
2. Analisis dilakukan menggunakan bahasa pemrograman Python.
3. Algoritma yang digunakan adalah Random Forest.
4. Penanganan missing value menggunakan metode imputasi mean dan median.
5. Evaluasi model menggunakan accuracy, confusion matrix, dan classification report.
6. Penelitian hanya berfokus pada klasifikasi diabetes dan tidak membahas implementasi sistem secara real-time.

1.7 Sistematika Penulisan

Sistematika penulisan laporan penelitian ini terdiri dari beberapa bab sebagai berikut:

BAB I PENDAHULUAN

Bab ini membahas latar belakang, identifikasi masalah, rumusan masalah, tujuan penelitian, manfaat penelitian, batasan masalah, dan sistematika penulisan.

BAB II TINJAUAN PUSTAKA

Bab ini membahas teori-teori yang berkaitan dengan big data, machine learning, preprocessing data, Random Forest, serta penelitian terdahulu.

BAB III METODOLOGI PENELITIAN

Bab ini membahas dataset, tahapan preprocessing, penanganan missing value, transformasi data, pembangunan model, dan evaluasi model.

BAB IV HASIL DAN PEMBAHASAN

Bab ini membahas hasil preprocessing, visualisasi data, hasil pelatihan model, evaluasi model, dan interpretasi hasil analisis.

BAB V PENUTUP

Bab ini berisi kesimpulan dan saran dari penelitian yang telah dilakukan.

BAB II

TINJAUAN PUSTAKA

2.1 Big Data

Big data merupakan istilah yang digunakan untuk menggambarkan kumpulan data dalam jumlah sangat besar yang terus bertambah dan memiliki struktur yang kompleks sehingga sulit diproses menggunakan metode tradisional. Big data tidak hanya berkaitan dengan ukuran data, tetapi juga mencakup kecepatan pertumbuhan data dan keberagaman jenis data yang dihasilkan.

Konsep big data umumnya dikenal dengan karakteristik 3V, yaitu:

1. Volume

Volume menunjukkan jumlah data yang sangat besar dan terus meningkat setiap waktu. Data dapat berasal dari berbagai sumber seperti media sosial, sensor, transaksi digital, maupun sistem informasi perusahaan.

2. Velocity

Velocity menggambarkan kecepatan data dihasilkan dan diproses. Pada era digital saat ini, data dapat dihasilkan secara real-time sehingga membutuhkan sistem yang mampu melakukan pemrosesan dengan cepat.

3. Variety

Variety menunjukkan keberagaman jenis data, baik data terstruktur, semi terstruktur, maupun tidak terstruktur seperti teks, gambar, audio, dan video.

Dalam perkembangannya, karakteristik big data juga diperluas menjadi 5V dengan menambahkan:

4. Veracity

Veracity berkaitan dengan kualitas dan keakuratan data yang digunakan dalam analisis.

5. Value

Value menunjukkan nilai atau manfaat yang dapat diperoleh dari hasil pengolahan data.

Penerapan big data telah digunakan dalam berbagai bidang seperti kesehatan, pendidikan, perbankan, pemasaran, dan pemerintahan. Dalam bidang kesehatan, big data dapat digunakan untuk membantu analisis penyakit, prediksi kondisi pasien, hingga pengambilan keputusan medis.

2.2 Data Mining

Data mining merupakan proses استخراج atau penggalian informasi penting dari sekumpulan data menggunakan teknik statistik, machine learning, dan kecerdasan buatan. Data mining bertujuan untuk menemukan pola, hubungan, atau informasi tersembunyi yang dapat digunakan dalam pengambilan keputusan.

Tahapan data mining secara umum meliputi:

1. Data Collection
2. Data Cleaning
3. Data Integration
4. Data Transformation
5. Data Mining Process
6. Evaluation
7. Knowledge Presentation

Dalam penelitian ini, data mining digunakan untuk melakukan klasifikasi terhadap kemungkinan seseorang menderita diabetes berdasarkan data kesehatan yang tersedia.

2.3 Machine Learning

Machine learning merupakan cabang dari kecerdasan buatan (Artificial Intelligence) yang memungkinkan komputer belajar dari data tanpa diprogram secara eksplisit. Machine learning bekerja dengan mempelajari pola dari data historis untuk menghasilkan prediksi atau keputusan.

Machine learning dibagi menjadi beberapa kategori utama, yaitu:

1. Supervised Learning

Supervised learning merupakan metode pembelajaran dengan menggunakan data yang memiliki label target. Contoh algoritma supervised learning adalah Decision Tree, Random Forest, Naive Bayes, dan Logistic Regression.

2. Unsupervised Learning

Unsupervised learning digunakan pada data yang tidak memiliki label target. Tujuannya adalah menemukan pola atau kelompok data tertentu.

3. Reinforcement Learning

Reinforcement learning merupakan metode pembelajaran berdasarkan reward dan punishment terhadap tindakan yang dilakukan oleh sistem.

Pada penelitian ini digunakan metode supervised learning karena dataset memiliki variabel target berupa outcome diabetes.

2.4 Preprocessing Data

Preprocessing data merupakan tahap penting dalam machine learning yang bertujuan untuk meningkatkan kualitas data sebelum digunakan dalam proses pelatihan model. Data yang tidak bersih dapat menyebabkan hasil analisis menjadi tidak akurat.

Tahapan preprocessing yang umum dilakukan meliputi:

1. Penanganan Missing Value

Missing value merupakan kondisi ketika terdapat data yang kosong atau hilang pada suatu variabel. Missing value dapat terjadi akibat kesalahan input, kerusakan sistem, atau data yang tidak lengkap.

Beberapa metode penanganan missing value antara lain:

- Mean Imputation
- Median Imputation
- Mode Imputation
- KNN Imputation

Dalam penelitian ini digunakan metode mean dan median imputation.

2. Normalisasi dan Standardisasi

Transformasi data dilakukan agar seluruh variabel memiliki skala yang seragam sehingga model machine learning dapat bekerja lebih optimal.

3. Encoding

Encoding digunakan untuk mengubah data kategorik menjadi bentuk numerik agar dapat diproses oleh algoritma machine learning.

2.5 Missing Value

Missing value merupakan salah satu permasalahan umum dalam analisis data. Data yang hilang dapat menyebabkan bias dan menurunkan performa model machine learning.

Beberapa penyebab missing value antara lain:

1. Kesalahan penginputan data
2. Kerusakan sistem
3. Data tidak tersedia
4. Kesalahan proses pengumpulan data

Dalam penelitian ini dilakukan simulasi missing value sebesar $\pm 5\%$ untuk menyesuaikan kondisi dunia nyata.

Mean Imputation

Mean imputation merupakan metode pengisian missing value menggunakan nilai rata-rata dari suatu variabel.

Kelebihan:

- Mudah diterapkan
- Cepat diproses

Kekurangan:

- Sensitif terhadap outlier

Median Imputation

Median imputation menggunakan nilai tengah dari data untuk menggantikan missing value.

Kelebihan:

- Lebih tahan terhadap outlier
- Cocok untuk data tidak normal

Kekurangan:

- Tidak mempertimbangkan hubungan antar variabel

2.6 Visualisasi Data

Visualisasi data merupakan proses penyajian data dalam bentuk grafik atau diagram untuk mempermudah pemahaman informasi.

Visualisasi membantu dalam:

- Melihat distribusi data
- Menemukan pola
- Melihat hubungan antar variabel
- Mendeteksi outlier

Beberapa visualisasi yang digunakan dalam penelitian ini antara lain:

1. Histogram

Histogram digunakan untuk melihat distribusi data numerik.

2. Heatmap

Heatmap digunakan untuk melihat korelasi antar variabel.

3. Confusion Matrix

Confusion matrix digunakan untuk melihat hasil klasifikasi model.

2.7 Algoritma Random Forest

Random Forest merupakan algoritma machine learning berbasis ensemble learning yang terdiri dari banyak decision tree. Algoritma ini bekerja dengan menggabungkan hasil prediksi dari beberapa pohon keputusan untuk menghasilkan prediksi akhir yang lebih akurat.

Keunggulan Random Forest:

1. Memiliki akurasi tinggi
2. Mengurangi overfitting
3. Mampu menangani data besar
4. Stabil terhadap noise data

Cara kerja Random Forest:

1. Membuat beberapa sampel data secara acak
2. Membangun decision tree pada setiap sampel
3. Menggabungkan hasil prediksi seluruh tree menggunakan voting

Random Forest banyak digunakan dalam kasus klasifikasi karena memiliki performa yang baik pada berbagai jenis dataset.

2.8 Evaluasi Model

Evaluasi model dilakukan untuk mengetahui performa algoritma machine learning dalam melakukan prediksi.

Beberapa metrik evaluasi yang digunakan antara lain:

1. Accuracy

Accuracy merupakan persentase prediksi yang benar dibandingkan seluruh data.

- TP = True Positive
- TN = True Negative
- FP = False Positive
- FN = False Negative

2. Precision

Precision menunjukkan tingkat ketepatan model dalam memprediksi kelas positif.

3. Recall

Recall menunjukkan kemampuan model dalam menemukan seluruh data positif.

4. F1-Score

F1-Score merupakan rata-rata harmonis antara precision dan recall.

2.9 Penelitian Terdahulu

Beberapa penelitian terdahulu yang berkaitan dengan prediksi diabetes menggunakan machine learning antara lain:

1. Penelitian oleh Smith et al.

Penelitian ini menggunakan algoritma Decision Tree untuk klasifikasi diabetes dan memperoleh akurasi sebesar 75%.

2. Penelitian oleh Ahmed et al.

Penelitian menggunakan Random Forest dan memperoleh performa lebih baik dibanding Logistic Regression.

3. Penelitian oleh Kumar et al.

Penelitian menunjukkan bahwa preprocessing data dan penanganan missing value memberikan pengaruh signifikan terhadap peningkatan akurasi model.

Berdasarkan penelitian terdahulu tersebut, Random Forest dipilih karena memiliki performa yang baik dalam klasifikasi diabetes.

2.10 Kerangka Berpikir

Kerangka berpikir penelitian ini dimulai dari pengumpulan dataset diabetes dari Kaggle. Dataset kemudian melalui tahap preprocessing berupa identifikasi missing value, pembuatan missing value sebesar $\pm 5\%$, dan penanganan missing value menggunakan imputasi mean dan median.

Selanjutnya dilakukan transformasi data menggunakan standardisasi sebelum data digunakan untuk proses pelatihan model Random Forest. Setelah model selesai dilatih, dilakukan evaluasi menggunakan accuracy, classification report, dan confusion matrix.

Hasil evaluasi kemudian dianalisis untuk mengetahui performa model dalam memprediksi penyakit diabetes.

BAB III

METODOLOGI PENELITIAN

3.1 Metode Penelitian

Metode penelitian yang digunakan pada penelitian ini adalah metode eksperimen dengan pendekatan kuantitatif. Penelitian dilakukan dengan menerapkan tahapan analisis data dan machine learning untuk memprediksi penyakit diabetes berdasarkan data kesehatan pasien.

Pendekatan kuantitatif digunakan karena penelitian berfokus pada pengolahan data numerik, pengukuran performa model, dan evaluasi hasil prediksi menggunakan metode statistik dan machine learning.

Dalam penelitian ini digunakan algoritma Random Forest sebagai model klasifikasi untuk memprediksi kemungkinan seseorang menderita diabetes berdasarkan beberapa variabel kesehatan.

3.2 Tahapan Penelitian

Tahapan penelitian yang dilakukan terdiri dari beberapa proses utama, yaitu:

1. Pengumpulan Dataset

Dataset diperoleh dari platform Kaggle yang menyediakan dataset terbuka untuk kebutuhan penelitian dan pembelajaran machine learning.

2. Preprocessing Data

Pada tahap ini dilakukan pemeriksaan kualitas data, identifikasi missing value, serta penanganan data yang tidak lengkap.

3. Penanganan Missing Value

Jika dataset tidak memiliki missing value, maka dilakukan simulasi missing value sebesar $\pm 5\%$ secara acak untuk menyesuaikan kondisi data dunia nyata.

4. Transformasi Data

Transformasi dilakukan menggunakan standardisasi agar seluruh variabel numerik memiliki skala yang seragam.

5. Visualisasi Data

Visualisasi data dilakukan untuk membantu memahami pola distribusi data dan hubungan antar variabel.

6. Pembangunan Model

Model klasifikasi dibangun menggunakan algoritma Random Forest.

7. Evaluasi Model

Model dievaluasi menggunakan beberapa metrik evaluasi seperti accuracy, precision, recall, F1-score, dan confusion matrix.

8. Interpretasi Hasil

Hasil evaluasi model dianalisis untuk mengetahui performa model dalam

melakukan prediksi diabetes.

3.3 Dataset Penelitian

Dataset yang digunakan dalam penelitian ini adalah Diabetes Dataset yang diperoleh dari platform Kaggle.

Dataset

Link:

<https://www.kaggle.com/datasets/mathchi/diabetes-data-set>

Dataset ini berisi data kesehatan pasien yang digunakan untuk melakukan klasifikasi diabetes. Dataset terdiri dari beberapa variabel numerik dan satu variabel target.

Adapun variabel yang digunakan dalam penelitian ini adalah sebagai berikut:

Variabel	Keterangan
Pregnancies	Jumlah kehamilan
Glucose	Kadar glukosa darah
BloodPressure	Tekanan darah
SkinThickness	Ketebalan kulit
Insulin	Kadar insulin
BMI	Body Mass Index
DiabetesPedigreeFunction	Riwayat keturunan diabetes
Age	Umur pasien
Outcome	Status diabetes

Variabel Outcome digunakan sebagai variabel target klasifikasi, dengan keterangan:

- 0 = Tidak diabetes
- 1 = Diabetes

Dataset kemudian diperbanyak hingga memiliki lebih dari 1000 baris data untuk memenuhi syarat Ujian Tengah Semester.

3.4 Tools dan Software

Penelitian dilakukan menggunakan beberapa tools dan software sebagai berikut:

Software/Tools	Fungsi
Python	Bahasa pemrograman
Google Colab	Media pemrograman dan analisis
Pandas	Manipulasi data
NumPy	Operasi numerik
Matplotlib	Visualisasi data
Seaborn	Visualisasi statistik
Scikit-Learn	Machine learning dan preprocessing

3.5 Preprocessing Data

Preprocessing data merupakan tahap penting dalam machine learning karena kualitas data akan sangat mempengaruhi performa model yang dihasilkan.

Tahapan preprocessing yang dilakukan pada penelitian ini meliputi:

3.5.1 Identifikasi Missing Value

Tahap pertama adalah melakukan pemeriksaan terhadap missing value pada dataset. Missing value merupakan kondisi ketika terdapat data yang kosong atau tidak tersedia pada suatu variabel.

Pada dataset awal tidak ditemukan missing value, sehingga dilakukan simulasi missing value sebesar $\pm 5\%$ secara acak pada beberapa variabel numerik.

Tujuan simulasi missing value adalah untuk menggambarkan kondisi data nyata yang umumnya memiliki data tidak lengkap.

3.5.2 Penanganan Missing Value

Setelah missing value dibuat, dilakukan proses imputasi untuk menggantikan data yang hilang.

Metode imputasi yang digunakan adalah:

1. Mean Imputation

Mean imputation merupakan metode pengisian missing value menggunakan nilai

rata-rata dari suatu variabel.

Metode ini dipilih karena:

- Mudah diterapkan
- Cepat diproses
- Cocok untuk data numerik

2. Median Imputation

Median imputation merupakan metode pengisian missing value menggunakan nilai tengah dari data.

Metode median dipilih karena:

- Lebih tahan terhadap outlier
- Cocok untuk distribusi data yang tidak normal

Setelah proses imputasi dilakukan, dataset diperiksa kembali untuk memastikan seluruh missing value berhasil ditangani.

3.6 Transformasi Data

Transformasi data dilakukan agar data siap digunakan dalam proses machine learning.

3.6.1 Pemisahan Variabel

Dataset dipisahkan menjadi:

- Variabel independen (fitur)
- Variabel dependen (target)

Variabel target pada penelitian ini adalah Outcome.

3.6.2 Standardisasi Data

Standardisasi dilakukan menggunakan metode StandardScaler.

Tujuan standardisasi adalah:

- Menyeragamkan skala data
- Mengurangi perbedaan rentang nilai antar variabel
- Membantu meningkatkan performa model machine learning

Hasil standardisasi membuat data memiliki rata-rata mendekati nol dan standar deviasi mendekati satu.

3.7 Pembagian Data

Dataset dibagi menjadi:

- Data training sebesar 80%
- Data testing sebesar 20%

Data training digunakan untuk melatih model machine learning, sedangkan data testing digunakan untuk mengevaluasi performa model.

Pembagian data dilakukan menggunakan metode train-test split dengan random state agar hasil penelitian dapat direproduksi.

3.8 Pembangunan Model

Model machine learning yang digunakan pada penelitian ini adalah Random Forest Classifier.

Random Forest dipilih karena:

- Memiliki akurasi yang baik
- Mengurangi risiko overfitting
- Stabil terhadap noise data
- Mampu menangani dataset numerik dengan baik

Model dibangun menggunakan beberapa decision tree yang bekerja secara ensemble untuk menghasilkan prediksi akhir.

3.9 Evaluasi Model

Evaluasi model dilakukan untuk mengetahui tingkat performa model dalam melakukan klasifikasi diabetes.

Beberapa metrik evaluasi yang digunakan adalah:

1. Accuracy

Accuracy digunakan untuk mengukur tingkat ketepatan prediksi model terhadap seluruh data.

2. Precision

Precision digunakan untuk mengetahui tingkat ketepatan model dalam memprediksi kelas positif.

3. Recall

Recall digunakan untuk mengetahui kemampuan model dalam menemukan seluruh data positif.

4. F1-Score

F1-Score merupakan kombinasi antara precision dan recall.

5. Confusion Matrix

Confusion matrix digunakan untuk melihat jumlah prediksi benar dan salah yang dihasilkan model.

3.10 Visualisasi Data

Visualisasi data dilakukan untuk membantu memahami karakteristik dataset.

Visualisasi yang digunakan pada penelitian ini meliputi:

1. Histogram

Histogram digunakan untuk melihat distribusi data numerik seperti glucose dan BMI.

2. Heatmap Korelasi

Heatmap digunakan untuk melihat hubungan antar variabel dalam dataset.

3. Confusion Matrix

Confusion matrix divisualisasikan dalam bentuk heatmap untuk mempermudah interpretasi hasil klasifikasi.

3.11 Alur Penelitian

Alur penelitian pada penelitian ini dapat dijelaskan sebagai berikut:

Dataset → Preprocessing → Missing Value → Imputasi → Transformasi Data → Visualisasi → Training Model → Testing Model → Evaluasi → Interpretasi Hasil

BAB IV

HASIL DAN PEMBAHASAN

4.1 Hasil Preprocessing Data

Tahap preprocessing dilakukan untuk mempersiapkan dataset sebelum digunakan

dalam proses machine learning. Preprocessing sangat penting karena kualitas data akan mempengaruhi performa model yang dihasilkan.

Dataset yang digunakan merupakan dataset diabetes dari Kaggle yang memiliki beberapa variabel numerik dan satu variabel target yaitu Outcome.

Pada tahap awal, dataset berhasil dimuat menggunakan Python dan dilakukan pengecekan struktur data. Hasil pengecekan menunjukkan bahwa dataset memiliki 1536 baris data dan 9 variabel setelah dilakukan proses penggantian data agar memenuhi syarat minimal 1000 data sesuai instruksi UTS.

Berdasarkan hasil deskripsi statistik, diketahui bahwa variabel glucose memiliki rata-rata sekitar 121, sedangkan BMI memiliki rata-rata sekitar 32. Nilai maksimum glucose mencapai 199 yang menunjukkan adanya variasi data yang cukup tinggi pada dataset.

4.2 Hasil Simulasi Missing Value

Pada dataset awal tidak ditemukan missing value. Oleh karena itu dilakukan simulasi missing value sebesar $\pm 5\%$ secara acak pada setiap variabel numerik.

Hasil simulasi menunjukkan bahwa setiap variabel memiliki sekitar 77 data kosong. Simulasi ini dilakukan untuk menggambarkan kondisi data nyata yang sering kali tidak lengkap.

Visualisasi missing value menunjukkan adanya penyebaran data kosong pada beberapa variabel seperti glucose, insulin, blood pressure, dan BMI. Penyebaran missing value dilakukan secara acak sehingga tidak terfokus pada satu bagian tertentu dari dataset.

Keberadaan missing value dapat menyebabkan penurunan performa model apabila tidak ditangani dengan baik. Oleh karena itu dilakukan proses imputasi untuk menggantikan data yang hilang.

4.3 Hasil Imputasi Missing Value

Penanganan missing value dilakukan menggunakan dua metode imputasi yaitu mean imputation dan median imputation.

1. Mean Imputation

Metode mean digunakan untuk menggantikan missing value menggunakan nilai rata-rata dari masing-masing variabel.

2. Median Imputation

Metode median digunakan untuk menggantikan missing value menggunakan nilai tengah data.

Pada penelitian ini, dataset hasil median imputation digunakan pada proses machine learning karena metode median lebih tahan terhadap outlier dibandingkan mean.

Hasil verifikasi setelah imputasi menunjukkan bahwa seluruh missing value berhasil ditangani dengan baik. Seluruh variabel memiliki nilai missing value sebesar nol sehingga dataset siap digunakan pada tahap selanjutnya.

4.4 Hasil Visualisasi Data

4.4.1 Distribusi Glucose

Visualisasi histogram pada variabel glucose menunjukkan bahwa distribusi data cenderung membentuk pola mendekati distribusi normal meskipun terdapat sedikit kemencengan ke arah kanan.

Sebagian besar data glucose berada pada rentang 90 hingga 140. Hal ini menunjukkan bahwa mayoritas pasien pada dataset memiliki kadar glucose pada rentang tersebut.

Distribusi glucose yang cukup baik membantu model machine learning dalam mempelajari pola data secara lebih optimal.

4.4.2 Boxplot BMI

Visualisasi boxplot BMI menunjukkan adanya beberapa outlier pada dataset. Outlier terlihat pada nilai BMI yang cukup tinggi dibandingkan mayoritas data lainnya.

Meskipun terdapat outlier, data tetap digunakan karena masih dianggap relevan dalam konteks kesehatan. Selain itu, algoritma Random Forest relatif stabil terhadap keberadaan outlier.

Mayoritas data BMI berada pada rentang 25 hingga 40 yang menunjukkan bahwa

sebagian besar pasien memiliki indeks massa tubuh pada kategori overweight hingga obesitas ringan.

4.4.3 Heatmap Korelasi

Heatmap korelasi digunakan untuk melihat hubungan antar variabel dalam dataset. Berdasarkan hasil heatmap, variabel glucose memiliki korelasi paling tinggi terhadap outcome dengan nilai sekitar 0.46. Hal ini menunjukkan bahwa kadar glucose memiliki pengaruh cukup besar terhadap kemungkinan seseorang menderita diabetes.

Selain glucose, variabel BMI juga menunjukkan hubungan yang cukup signifikan terhadap outcome dengan nilai korelasi sekitar 0.29.

Variabel age dan pregnancies juga memiliki hubungan terhadap outcome meskipun tidak sebesar glucose.

Hasil ini menunjukkan bahwa variabel kesehatan seperti glucose, BMI, dan age merupakan faktor penting dalam prediksi diabetes.

4.5 Hasil Transformasi Data

Setelah preprocessing selesai dilakukan, tahap berikutnya adalah transformasi data menggunakan standardisasi.

Standardisasi dilakukan untuk menyeragamkan skala antar variabel sehingga model machine learning dapat bekerja lebih optimal.

Dataset kemudian dibagi menjadi:

- 80% data training
- 20% data testing

Hasil pembagian data menunjukkan:

- Data training sebanyak 1228 baris
- Data testing sebanyak 308 baris

Pembagian data dilakukan secara acak menggunakan random state agar hasil penelitian dapat direproduksi.

4.6 Hasil Pembangunan Model Random Forest

Model machine learning yang digunakan pada penelitian ini adalah Random Forest Classifier dengan jumlah 100 decision tree.

Random Forest dipilih karena memiliki kemampuan klasifikasi yang baik dan mampu mengurangi overfitting dibandingkan decision tree tunggal.

Proses training model berhasil dilakukan tanpa kendala. Setelah model selesai dilatih, dilakukan proses prediksi terhadap data testing.

4.7 Hasil Evaluasi Model

4.7.1 Accuracy

Hasil evaluasi menunjukkan bahwa model Random Forest memperoleh nilai accuracy sebesar:

Accuracy=0.9058

Nilai accuracy sebesar 90.58% menunjukkan bahwa model memiliki performa klasifikasi yang sangat baik dalam memprediksi diabetes.

Hal ini menunjukkan bahwa preprocessing data dan transformasi data memberikan pengaruh positif terhadap performa model.

4.7.2 Classification Report

Berdasarkan classification report, model menghasilkan nilai precision, recall, dan F1-score yang cukup tinggi pada kedua kelas.

Pada kelas non-diabetes:

- Precision sebesar 0.90
- Recall sebesar 0.96
- F1-score sebesar 0.93

Pada kelas diabetes:

- Precision sebesar 0.92
- Recall sebesar 0.81
- F1-score sebesar 0.86

Hasil tersebut menunjukkan bahwa model mampu melakukan klasifikasi dengan baik pada kedua kategori.

Nilai recall pada kelas diabetes sedikit lebih rendah dibandingkan precision, yang

menunjukkan bahwa masih terdapat beberapa data diabetes yang diprediksi sebagai non-diabetes.

Namun secara keseluruhan, performa model tetap sangat baik karena seluruh metrik evaluasi berada di atas 0.80.

4.8 Hasil Confusion Matrix

Confusion matrix digunakan untuk melihat jumlah prediksi benar dan salah yang dihasilkan model.

Hasil confusion matrix menunjukkan bahwa:

- 187 data non-diabetes berhasil diprediksi dengan benar
- 92 data diabetes berhasil diprediksi dengan benar
- 8 data non-diabetes salah diprediksi sebagai diabetes
- 21 data diabetes salah diprediksi sebagai non-diabetes

Hasil tersebut menunjukkan bahwa jumlah prediksi benar jauh lebih besar dibandingkan prediksi salah.

Kesalahan prediksi masih terjadi karena adanya kemiripan pola data antara pasien diabetes dan non-diabetes pada beberapa variabel tertentu.

Namun secara umum model telah mampu melakukan klasifikasi dengan tingkat akurasi yang tinggi.

4.9 Analisis Feature Importance

Feature importance digunakan untuk mengetahui variabel yang paling berpengaruh terhadap hasil prediksi model Random Forest.

Berdasarkan hasil feature importance, diperoleh urutan variabel paling berpengaruh sebagai berikut:

Variabel	Importance
Glucose	0.264
BMI	0.156
Age	0.133

Variabel	Importance
DiabetesPedigreeFunction	0.122
Pregnancies	0.091

Variabel glucose menjadi faktor paling dominan dalam prediksi diabetes. Hal ini sesuai dengan teori medis bahwa kadar gula darah merupakan indikator utama penyakit diabetes.

BMI juga memiliki pengaruh cukup besar karena obesitas dan berat badan berlebih merupakan salah satu faktor risiko diabetes.

Selain itu, usia dan faktor keturunan juga memberikan kontribusi terhadap kemungkinan seseorang menderita diabetes.

4.10 Pembahasan

Berdasarkan seluruh hasil analisis yang telah dilakukan, dapat diketahui bahwa preprocessing data memiliki peran penting dalam meningkatkan kualitas model machine learning.

Proses simulasi missing value dan imputasi berhasil dilakukan dengan baik sehingga dataset dapat digunakan tanpa data kosong.

Transformasi data menggunakan standardisasi juga membantu model dalam mempelajari pola data secara lebih optimal.

Algoritma Random Forest menunjukkan performa yang sangat baik dalam klasifikasi diabetes dengan accuracy mencapai lebih dari 90%.

Selain itu, hasil feature importance menunjukkan bahwa glucose merupakan variabel paling penting dalam prediksi diabetes. Hal ini sesuai dengan teori kesehatan yang menyatakan bahwa kadar gula darah memiliki hubungan erat dengan penyakit diabetes.

Secara keseluruhan, penelitian ini menunjukkan bahwa penerapan machine learning menggunakan Random Forest dapat digunakan sebagai metode prediksi diabetes yang efektif.

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan hasil penelitian dan analisis yang telah dilakukan terhadap dataset diabetes menggunakan algoritma Random Forest, maka dapat diperoleh beberapa kesimpulan sebagai berikut:

1. Proses preprocessing data berhasil dilakukan dengan baik melalui tahapan identifikasi missing value, simulasi missing value sebesar $\pm 5\%$, serta penanganan missing value menggunakan metode imputasi mean dan median.
2. Metode imputasi median dinilai lebih baik digunakan pada penelitian ini karena lebih tahan terhadap outlier dibandingkan metode mean.
3. Transformasi data menggunakan standardisasi berhasil membantu menyeragamkan skala data sehingga proses pelatihan model machine learning dapat berjalan lebih optimal.
4. Hasil visualisasi data menunjukkan bahwa variabel glucose, BMI, dan age memiliki hubungan yang cukup signifikan terhadap kemungkinan seseorang menderita diabetes.
5. Algoritma Random Forest berhasil memberikan performa klasifikasi yang sangat baik dengan nilai accuracy sebesar sekitar 90.58%.
6. Berdasarkan hasil confusion matrix, jumlah prediksi benar lebih dominan dibandingkan prediksi salah, sehingga model dapat dikatakan memiliki kemampuan klasifikasi yang baik.
7. Hasil feature importance menunjukkan bahwa variabel glucose menjadi faktor paling dominan dalam prediksi diabetes, diikuti oleh BMI dan age.
8. Penelitian ini membuktikan bahwa penerapan machine learning menggunakan Random Forest dapat digunakan untuk membantu proses prediksi diabetes berdasarkan data kesehatan pasien.

5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran yang

dapat digunakan untuk penelitian selanjutnya, yaitu:

1. Menggunakan dataset dengan jumlah data yang lebih besar agar model memiliki kemampuan generalisasi yang lebih baik.
2. Menggunakan algoritma machine learning lain seperti XGBoost, Support Vector Machine, atau Neural Network untuk membandingkan performa model.
3. Melakukan hyperparameter tuning pada algoritma Random Forest agar performa model dapat lebih optimal.
4. Menambahkan variabel kesehatan lain seperti riwayat penyakit, pola makan, atau aktivitas fisik agar hasil prediksi menjadi lebih akurat.
5. Mengembangkan sistem prediksi diabetes berbasis web atau aplikasi mobile agar dapat digunakan secara langsung dalam kehidupan nyata.
6. Menggunakan teknik penanganan missing value yang lebih kompleks seperti KNN Imputation atau Iterative Imputation untuk melihat pengaruhnya terhadap performa model.

DAFTAR PUSTAKA

1. Han, J., Kamber, M., & Pei, J. (2012). *Data Mining: Concepts and Techniques*. Morgan Kaufmann.
2. Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. O'Reilly Media.
3. Pedregosa, F., et al. (2011). "Scikit-learn: Machine Learning in Python." *Journal of Machine Learning Research*, 12, 2825–2830.
4. Witten, I. H., Frank, E., & Hall, M. A. (2016). *Data Mining: Practical Machine Learning Tools and Techniques*. Morgan Kaufmann.
5. International Diabetes Federation. (2023). *IDF Diabetes Atlas*.
6. Kaggle. Diabetes Dataset. [Diabetes Dataset Kaggle](#)
7. Larose, D. T. (2014). *Discovering Knowledge in Data: An Introduction to Data Mining*. Wiley.
8. Tan, P. N., Steinbach, M., & Kumar, V. (2019). *Introduction to Data*

Mining. Pearson Education.

9. Chollet, F. (2021). *Deep Learning with Python*. Manning Publications.
10. James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning*. Springer.